

Apprentissage automatique quantique avec des modes bosoniques

Résumé détaillé et analyse critique

Analyse de la thèse de doctorat de Julien Dudas du 30/10/2025

La thèse de Julien Dudas [1] étudie, principalement par la simulation numérique, la mise en œuvre de réseaux de neurones à partir de modes bosoniques couplés, dans le cadre de l'apprentissage automatique quantique et du calcul neuromorphique. Elle explore deux voies d'entraînement : (i) le calcul par réservoir quantique, où la non-linéarité provient de la mesure dans la base de Fock, (ii) et l'entraînement direct des couplages paramétriques à trois sondes par descente de gradient, rendu possible par une restriction aux états gaussiens simulables efficacement. Ce document propose un résumé détaillé de la thèse, puis une analyse critique de ses forces et de ses limites (absence de validation expérimentale, régime gaussien simulable classiquement, tâches de petite taille, non-scalabilité de la rétropropagation).

I. CONTEXTE

La thèse de Julien Dudas, *Quantum machine learning with bosonic modes*, a été préparée au Laboratoire Albert Fert.

Son travail se situe à l'intersection de deux champs : le **calcul neuromorphique** — qui cherche à exécuter des réseaux de neurones directement sur du matériel physique pour en réduire le coût énergétique — et l'**apprentissage automatique quantique** (QML), qui espère tirer parti des propriétés quantiques (superposition, intrication) pour augmenter la puissance de calcul. L'objet d'étude central est le *mode bosonique* : un oscillateur harmonique quantique dont les niveaux d'énergie, les états de Fock $|n\rangle$, servent de briques de calcul. La thèse est essentiellement une étude de *simulation numérique*, orientée vers une implémentation future en électrodynamique quantique de circuits supraconducteurs.

II. PROBLÉMATIQUE

Point de départ. Le cerveau traite l'information avec une efficacité énergétique remarquable (environ 20 W). Les réseaux de neurones artificiels s'en inspirent, mais puisqu'ils s'exécutent sur une architecture de von Neumann qui sépare mémoire et calcul, l'entraînement de gros modèles impose un va-et-vient de données coûteux : c'est le *goulet d'étranglement de von Neumann*. Donc, si l'on veut des modèles soutenables, il faut sortir de cette architecture et calculer directement dans un substrat physique — l'idée du calcul neuromorphique.

Étape suivante. Si l'on cherche un substrat physique à la fois compact et très expressif, les systèmes quantiques deviennent attractifs : la dimension de leur espace d'états (l'espace de Hilbert) croît *exponentiellement* avec le nombre de constituants. On peut alors voir les états de base comme des neurones et les amplitudes de transition comme des synapses, ce qui offre un espace de représentation gigantesque pour un matériel de taille modeste. *Donc* un système quantique bien contrôlé pourrait, en principe, réaliser un réseau de neurones très expressif sans multiplier le nombre de composants physiques.

Le dilemme. Reste à savoir comment entraîner un tel système. Deux familles existent, et chacune bute sur un obstacle propre :

- les **circuits quantiques paramétrés** (PQC) [Figure 1] entraînent directement les paramètres physiques (angles de portes) par descente de gradient. Ils sont expressifs, mais *puisque* l'espace de Hilbert est immense, les gradients mesurés s'annulent exponentiellement avec la taille du système : c'est le phénomène des *barren plateaus*, qui rend l'entraînement à grande échelle actuellement impraticable ;




FIGURE 1. A Quantum Neural Network architecture.

- le **calcul par réservoir quantique** (QRC) [Figure 2] contourne le problème en n'entraînant *aucun* paramètre physique : le système quantique, laissé fixe et aléatoire, projette les données dans un espace de grande dimension, et seule une régression linéaire classique en sortie est apprise. L'entraînement est donc trivial et sans barren plateau, mais *puisque* il ne comporte qu'une seule couche linéaire apprise, son expressivité est faible, et il faut mesurer un grand nombre d'observables pour obtenir de bonnes performances.

Le pari de la thèse. Face à ce dilemme, Dudas fait deux choix. D'abord, travailler avec des **modes bosoniques** plutôt qu'avec des qubits : là où un qubit n'a que deux niveaux, un mode bosonique en possède une infinité




FIGURE 2. A Quantum Reservoir Schema.

(une dizaine sont utilisés en pratique), ce qui multiplie les états de base — donc les « neurones » — par composant physique. Ensuite, résoudre en deux temps la question de l'entraînement : la première partie explore la voie réservoir (chapitre 4), la seconde la voie de l'entraînement direct (chapitre 5).

III. LES FONDATIONS THÉORIQUES

Le chapitre 2 rappelle d'abord les bases de l'apprentissage automatique classique : le perceptron multicouche, où des neurones appliquant une fonction d'activation non linéaire sont reliés par des poids synaptiques linéaires ; l'entraînement par descente de gradient, qui met à jour les paramètres selon $\theta^{(n+1)} = \theta^{(n)} - \gamma \nabla_{\theta} C(\theta^{(n)})$; et l'algorithme de rétropropagation qui calcule ces gradients efficacement. Il enchaîne sur les circuits quantiques paramétrés, en introduisant deux notions décisives pour la suite : les *parameter shift rules*, qui permettent d'obtenir des gradients analytiques exacts à partir de deux passes du circuit, et les *barren plateaus*, ces zones où le gradient s'évanouit exponentiellement avec la taille du système et paralysent l'entraînement. Pour un paramètre donnée θ_j , et n_q le nombre de qubits alors on définit un Barren Plateau si :

$$\text{Var}(\nabla_{\theta_j} C) \in \mathcal{O}\left(\frac{1}{b^{n_q}}\right)$$

. La variance du gradient de la fonction de coût C tend exponentiellement vite vers 0.

Le chapitre 3 introduit le calcul par réservoir. Puisqu'entraîner un réseau récurrent est difficile, l'idée est de figer la partie récurrente (le « réservoir ») et de n'apprendre que la lecture linéaire de sortie ; l'*echo state network* en est la version classique canonique, et sert de point de comparaison dans la thèse [Figure 3] .

Le chapitre décrit ensuite le passage au réservoir quantique sur qubits, puis les différents protocoles de mesure (*restarting*, *rewinding*, mesures faibles en ligne) qui gèrent le fait qu'une mesure quantique projette et perturbe l'état — un point technique important, car il conditionne la façon dont un système quantique peut « se souvenir » d'entrées passées tout en étant mesuré.




FIGURE 3. Classical Echo State Network.

IV. RÉSUMÉ DÉTAILLÉ I — LE RÉSERVOIR BOSONIQUE (CHAP. 4)

A. Non-linéarité par la mesure

Un réseau de neurones a besoin de non-linéarité pour séparer des données. Or un mode bosonique isolé, décrit par le hamiltonien $\hat{H} = \omega \hat{a}^\dagger \hat{a}$, a une dynamique *linéaire*. Donc la non-linéarité doit venir d'ailleurs. Le choix central de cette partie est de la faire émerger de la **mesure elle-même** : lire l'état dans la base de Fock (compter les photons) est une opération non linéaire vis-à-vis des amplitudes du champ. Ce choix a un double intérêt : il fournit la non-linéarité requise *et* il livre, d'un seul coup, un grand nombre de caractéristiques de sortie (les probabilités d'occupation des différents états $|n\rangle$) — exactement ce dont un réservoir a besoin, puisque tout l'apprentissage repose sur la couche linéaire appliquée à ces caractéristiques [Figure 4].




FIGURE 4. Different choices to integrate non-linearities in Bosonic Reservoirs.

Concrètement, deux modes bosoniques (réalisables comme modes électromagnétiques de résonateurs supraconducteurs) [Figure 5] sont pilotés par des *drives* quasi résonants qui y injectent des photons, et couplés par un élément non linéaire (jonction Josephson). Les données d'entrée sont encodées dans les amplitudes des drives,

le système évolue librement (ce qui lui confère une mémoire, essentielle aux tâches temporelles), puis on mesure les occupations de Fock qui constituent le vecteur de caractéristiques.




FIGURE 5. A Schema of two Bosonic modes coupled with g .

B. Résultats et interprétation

Le réservoir bosonique est évalué sur deux tâches de référence : la classification de formes d'onde sinus/carré (qui exige de la non-linéarité) et la prédiction de la série temporelle chaotique de Mackey–Glass.

Efficacité en nombre de caractéristiques. Comparé à un réservoir classique (*echo state network*) sur la tâche sinus/carré, le réservoir quantique résout la tâche en mesurant **4 caractéristiques au lieu de 17** [Figure 6]. Pour la même puissance de traitement, il faut donc moins de dispositifs physiques et moins de grandeurs à mesurer [Figure 7].




FIGURE 6. Performance comparison of the quantum, and classical reservoirs. Test accuracy on the sin/square waveform classification tasks as a function of the number of reservoir neurons, for a classical reservoir (ESN), and for the bosonic QRC. The classical reservoir accuracy is averaged over 100 random initializations. For the bosonic QRC, the number of measured joint Fock states corresponds to the number of reservoir neurons.

Le rôle de la cohérence quantique. Pour comprendre l'origine de cet avantage, l'auteur simule le même réservoir dans sa « limite classique », en ajoutant un fort déphasage qui détruit les cohérences quantiques. Puisque les performances se dégradent alors (il faut 9 caractéristiques au lieu de 4), on en déduit que les cohérences jouent un rôle actif : elles augmentent le nombre d'états




FIGURE 7. Reservoir performance on the sin/square waveform classification task, for (a) 4 or (b) 9 measured Fock probability amplitudes. The input data (green dots) is a time series of points belonging to a sine or square discretized in 8 points. The target label is 1 if the point belongs to a sine, or 0 if it belongs to a square. The prediction (purple dots) is separated by a threshold (black dashed line), for which the prediction is 0 if the output is below the threshold, or 1 if it is above.

effectivement accessibles pour le calcul dans l'espace de Hilbert, y compris des états non mesurés qui participent à la dynamique. Cette expérience contrôlée est l'un des arguments les plus marquant de la thèse.

Le coût des mesures. Revers de la médaille, les mesures quantiques sont stochastiques. Atteindre 100 % d'exactitude sur la tâche sinus/carré avec 4 observables requiert de l'ordre de 10^7 à 10^9 répétitions de mesure, l'incertitude relative sur une probabilité P décroissant en $\sqrt{(1-P)/(N_{\text{shots}} P)}$.

C. Limites reconnues

Deux limites motivent la suite. D'une part, il faut encore mesurer *beaucoup* d'observables, ce qui pèse lourd expérimentalement puisque chaque mesure est coûteuse. D'autre part, n'apprendre qu'une seule couche linéaire borne l'expressivité. *Donc*, pour progresser, il faut cesser de laisser le système fixe et entraîner ses paramètres physiques — ce qui fait le pont vers la seconde partie.

V. RÉSUMÉ DÉTAILLÉ II — LE RÉSEAU ANALOGIQUE ENTRAÎNÉ (CHAP. 5)

A. Rendre les couplages entraînaables

L'idée directrice est d'introduire des **paramètres physiques ajustables** entre les modes, puis de les optimiser. Ces paramètres proviennent du *mélange à trois ondes* : selon la fréquence de la pompe appliquée au système, on active soit la *conversion cohérente de photons* (pompe à la différence des fréquences des modes), soit

le *squeezing* à deux modes (pompe à leur somme). Amplitudes, phases et désaccords des drives et des pompes deviennent autant de paramètres entraînables, dont certains servent aussi à encoder les données. L'approche est *analogique* : plutôt que d'enchaîner de nombreuses portes distinctes, on applique une seule évolution et on exploite la richesse de sa dynamique [Figure 8].




FIGURE 8. Schematic of an analog quantum neural network. The input data vector x (green squares) is encoded into a parameter $\theta_{enc}(x) = \theta_0 \odot x + \theta_{bias}$, and the feature vector $f(x)$ (purple squares) is obtained by measuring a set of local probabilities $\{P_k(n)_{k,n}\}$ of a mode k to contain n photons. The prediction $\bar{y}$ (red squares) is obtained by multiplying the feature vector by a trained weight matrix W_0 , with bias W_{bias} .

B. L'astuce de simulation : rester gaussien

Entraîner par descente de gradient suppose d'exécuter énormément de passes en avant ; il faut donc une simulation rapide et scalable. Or simuler l'équation maîtresse de Lindblad dans la représentation de Schrödinger coûte un temps exponentiel en nombre de modes. Donc l'auteur se restreint aux **états gaussiens**, entièrement caractérisés par un vecteur de déplacement et une matrice de covariance — soit un nombre *polynomial* de variables. Leur dynamique se calcule en $\mathcal{O}(M^3)$ dans la représentation de Heisenberg, et les probabilités de Fock s'obtiennent analytiquement par la formule du *Gaussian boson sampling*. Sur cette base, Dudas a développé une bibliothèque Python entièrement différentiable (via PyTorch) permettant d'entraîner les paramètres physiques par rétropropagation, dans l'esprit du *chip-in-the-loop*.

Le prix à payer est explicite : puisque tout terme non quadratique du hamiltonien briserait le caractère gaussien de l'état, seuls la conversion de photons et le squeezing à deux modes sont autorisés (pas d'effet Kerr, par exemple). La question que la partie cherche à trancher est donc précise : à nombre de modes fixé, entraîner ces couplages apporte-t-il un gain en expressivité et en nombre d'observables à mesurer, par rapport au réservoir ?

C. Résultats

Sinus/carré. L'entraînement fait tomber le nombre d'observables à mesurer de 4 (en QRC) à **une seule**, et il suffit d'environ 10^3 mesures pour conserver la performance [Figure 9].




FIGURE 9. Accuracy on the sin/square classification task as a function of the number of training epochs for two different numbers of measurement shots used to determine the probability $P_1(0)$.

La raison est instructive : le réseau entraîné apprend à concentrer l'information sur un unique état de Fock à forte probabilité d'occupation, là où le réservoir devait répartir la lecture sur quatre états peu peuplés.

Spirales. Pour une tâche plus difficile, l'auteur passe à 4 modes couplés (afin de disposer d'assez d'amplitudes complexes pour l'encodage) et compare les schémas d'encodage (amplitude ou phase des drives, taux de conversion de photons, taux de squeezing) [Figure 10].




FIGURE 10. Impact of the encoding variable on the performance on the spirals classification task. The accuracy for different encoding schemes is shown as a function of the number of measured probabilities. Since the accuracies obtained when encoding in g vary greatly with the initial physical parameters $\{g, g^s, \delta, \epsilon\}$, we average them over 5 random initial sets of parameters.

TABLE I. Apport de l'entraînement (partie II) par rapport au réservoir (partie I), à taille de système comparable.

Tâche	Réservoir (QRC)	Réseau entraîné
Sinus / carré	4 états mesurés	1 état mesuré
Spirales	réf. MLP : 79 param.	38 param., 1 état
Chiffres manuscrits	62,8 % (36 états)	97 % (12 états)

Certaines combinaisons font diverger le nombre de photons ; des règles de « clamping » sont introduites pour stabiliser l'entraînement. Le meilleur résultat vient de l'encodage dans le *taux de squeezing à deux modes*, qui résout la tâche avec un seul état de Fock mesuré, ce que l'auteur attribue à son influence plus forte sur la matrice de covariance — un nouvel indice du rôle des cohérences. Le réseau bosonique n'a besoin que de **38 paramètres**, contre 79 pour le plus petit perceptron à deux couches résolvant la même tâche.

Chiffres manuscrits (DIGITS). Sur une tâche nettement plus complexe, le réseau entraîné atteint **97 % d'exactitude en mesurant 12 états de Fock**, tandis qu'un réservoir de taille équivalente plafonne à **62,8 % en mesurant 36 états**. L'entraînement augmente donc l'expressivité au point de résoudre des tâches hors de portée d'un réservoir de même taille — un avantage précieux compte tenu de la difficulté à agrandir un système quantique.




FIGURE 11. Comparison of the bosonic QNN performance to that of quantum reservoir computing on the DIGITS dataset classification task, with 6 modes. The classification accuracy on the test dataset is plotted as a function of the learning epoch. 12 probabilities are measured for the bosonic QNN, while 36 are measured for the quantum reservoir, whose accuracies reaches at best 62.8%.

D. Limites reconnues

L'auteur souligne lui-même que la rétropropagation n'est *pas* scalable : elle exige de simuler classiquement le système pour obtenir les gradients. Pour de plus grands réseaux, des méthodes d'entraînement « compa-

tibles avec la physique » (propagation à l'équilibre, algorithme *forward-forward*) seront nécessaires. Le passage aux états non gaussiens (effet Kerr, mélange à quatre ondes), qui débloquerait des ressources proprement quantiques, est renvoyé aux perspectives.

VI. FIL CONDUCTEUR ET APPORTS

La cohérence de la thèse tient à un enchaînement clair : un besoin de non-linéarité résolu par la mesure de Fock (partie I), puis un besoin d'expressivité et d'économie de mesures résolu par l'entraînement des couplages (partie II), chaque limite d'une étape motivant la suivante. Les apports les plus solides sont conceptuels et méthodologiques : (i) l'idée d'exploiter la *mesure* comme source de non-linéarité et comme extracteur massif de caractéristiques ; (ii) une démonstration contrôlée du rôle des cohérences quantiques via la limite classique par déphasage ; (iii) un cadre de simulation gaussienne entièrement différentiable permettant l'entraînement analogique par rétropropagation, réutilisable au-delà de cette thèse.

VII. ANALYSE CRITIQUE

A. Limites et réserves

Tout repose sur la simulation. Aucun résultat expérimental ne vient étayer les promesses ; l'annexe sur la mesure dispersive des états de Fock reste préliminaire. L'écart entre simulation et matériel réel — bruit des pompes, pertes, décohérence effective, imperfections de calibration — n'est pas quantifié, alors qu'il conditionne la portée pratique des conclusions.

Une tension au cœur du dispositif : gaussien = simulable classiquement. Le régime gaussien est précisément celui que l'on sait simuler efficacement sur un ordinateur classique. La thèse le choisit pour rendre l'entraînement faisable, mais ce faisant elle se place dans un régime où un *avantage quantique* au sens fort n'est pas établi : si un ordinateur classique reproduit toute la dynamique en temps polynomial, l'intérêt devient celui d'un accélérateur analogique économe, non celui d'une suprématie de calcul. La non-linéarité de mesure et le rôle des cohérences sont réels, mais la démonstration d'un gain que le classique ne pourrait égaler reste à faire — et l'auteur, à juste titre, ne le revendique pas.

Des tâches encore modestes. Sinus/carré, spirales et chiffres manuscrits en basse résolution sont des bancs d'essai utiles mais éloignés d'applications réalistes. Rien n'établit que les avantages observés (économie de mesures, expressivité) se maintiennent à plus grande échelle, ni sur des données de dimension élevée.

Des comparaisons dépendantes des références choisies. Les gains affichés (« 4 contre 17 caractéristiques », « 38 contre 79 paramètres ») dépendent fortement des baselines retenues, et le perceptron n'est pas

nécessairement le point de comparaison le plus exigeant. Par ailleurs, comparer un *nombre de paramètres* à un *nombre d'observables physiques* met en regard des coûts hétérogènes ; une comptabilité en coût total (mesures $\times$ répétitions, temps de calibration, énergie) donnerait une image plus juste. Sur ce point, le coût de 10^7 – 10^9 mesures du réservoir reste potentiellement rédhibitoire, et n'est réduit à 10^3 que sur les petites tâches après entraînement.

Des arguments prospectifs non démontrés. L'idée que les réseaux bosoniques seraient intrinsèquement moins sujets aux barren plateaus est plausible mais reste spéculative : elle n'est pas prouvée. De même, la robustesse à la décohérence et la scalabilité au-delà de 2

à 4 modes sont identifiées comme ouvertes, alors qu'elles sont décisives pour juger de la valeur réelle de l'approche.

B. Questions ouvertes

Trois questions structurent la suite naturelle de ce travail : le passage à la non-gaussianité peut-il être maîtrisé sans faire exploser le coût de simulation ou d'entraînement ? Une méthode d'entraînement compatible avec la physique permettra-t-elle de se passer d'un modèle classique du système ? Et l'avantage observé survit-il au passage sur matériel réel, une fois la décohérence et le bruit de mesure pris en compte ?

[1] Dudas, J. *Apprentissage automatique quantique avec des modes bosoniques*. Thèse de doctorat, Université Paris-Saclay, Laboratoire Albert Fert (CNRS/Thales) (2025).

URL https://laboratoire-albert-fert.cnrs-thales.fr/wp-content/uploads/2026/02/these_dudas.pdf.